Título del tfg en español

Título del tfg en inglés

Trabajo Fin de Grado en Matemáticas
Universidad de Málaga

Autor: Guillermo Cascales Ñíguez

Área de conocimiento y/o departamento: Departamento de Análisis Matemático, Estadística e Investigación Operativa y Matemática Aplicada

Fecha de presentación: (mes y año)

Tema:

Tipo: (trabajo de revisión bibliográfica, de iniciación a la investigación,...)

Modalidad: (individual o grupal)

Número de páginas (sin incluir introducción, bibliografía ni anexos):

DECLARACIÓN DE ORIGINALIDAD DEL TFG

D./Dña. *(nombre del autor)*, con DNI (NIE o pasaporte) *(DNI, NIE o pasaporte)*, estudiante del Grado en *(titulación)* de la Facultad de Ciencias de la Universidad de Málaga, **DECLARO:**

Que he realizado el Trabajo Fin de Grado titulado "*(Título)*" y que lo presento para su evaluación. Dicho trabajo es original y todas las fuentes bibliográficas utilizadas para su realización han sido debidamente citadas en el mismo.

De no cumplir con este compromiso, soy consciente de que, de acuerdo con la normativa reguladora de los procesos de evaluación de los aprendizajes del estudiantado de la Universidad de Málaga de 23 de julio de 2019, esto podrá conllevar la calificación de suspenso en la asignatura, sin perjuicio de las responsabilidades disciplinarias en las que pudiera incurrir en caso de plagio.

Para que así conste, firmo la presente en Málaga, el *(fecha)*

Fdo:.....

Índice general

Resumen I

Abstract I

Introducción I

1. Introducción al aprendizaje automático **1**
1. Conceptos básicos 1
1.1. Subsección 3
1.2. Subsección 3

2. Título del capítulo **4**
1. Una primera sección 4
1.1. Subsección 4
1.2. Subsección 5

Bibliografía **5**

El Título aquí

Resumen

Este Trabajo Fin de Grado se sitúa en el ámbito del aprendizaje automático (Machine Learning). En particular, se analiza en profundidad la arquitectura de las Redes Neuronales para luego ser aplicadas en el campo de la detección de anomalías, encargado de encontrar patrones o eventos que se salgan de la normalidad en un sistema. En primer lugar, se analizan desde un enfoque teórico los elementos básicos de la teoría del Machine Learning, como los de clasificador, función de pérdida, error de entrenamiento y test, aprendizaje PAC, dimensión VC, red neuronal, función de activación o entrenamiento, de los que este trabajo se sirve para mostrar los resultados y métodos centrales en este área como pueden ser el teorema fundamental del aprendizaje PAC, el descenso de gradiente, la regularización o los autoencodificadores. Finalmente, el marco teórico desarrollado se ejemplifica experimentalmente mediante una aplicación práctica sobre un dataset real de detección de fraude en transacciones financieras con tarjetas de crédito.

Palabras clave:

Aprendizaje automático, Redes neuronales, Aprendizaje PAC, Autoencodificadores, Detección de anomalías, Redes neuronales de replicación.

El Título (en inglés) aquí

Abstract

Text.

key words:

KEY WORDS.

Introducción

Desde tiempos inmemoriales, los humanos hemos soñado con crear una máquina que fuese capaz de pensar. En cuanto aparecieron los primeros ordenadores, no tardamos mucho tiempo en imaginarnos un futuro con robots que tuvieran capacidad de raciocinio, que pudiesen juzgar de la misma forma y facilidad con la que una persona lo hace.

En sus primeros días, la *inteligencia artificial* (IA) resolvió rápidamente problemas intelectualmente complicados para los humanos. Por ejemplo, el ENIAC, uno de los primeros computadores de propósito general, era capaz de calcular la potencia 660.000 de un número de 10 cifras en tan sólo 1,5 segundos, y fue inicialmente diseñado para calcular tablas de tiro de artillería destinadas al Laboratorio de Investigación Balística del Ejército de los Estados Unidos.

Pero el verdadero reto no era resolver problemas que pudieran ser descritos mediante una lista de reglas matemáticas y formales, sino aquellas tareas que son sencillas y automáticas para las personas, como reconocer una cara o el lenguaje hablado, pero al mismo tiempo muy difíciles de describir formalmente. Los primeros intentos de atacar a este problema se basaban principalmente en una serie de reglas. En el caso de identificar lenguaje hablado, el algoritmo busca si la persona está diciendo una letra en particular. Pero cada persona tiene un tono distinto, por lo que un conjunto de reglas que buscase cada letra y se tuviese que adaptar al tono y acento del usuario, además de poco efectivo sería muy tedioso de elaborar.

En su lugar, podemos elaborar un algoritmo que no resolverá directamente la tarea, sino que usará datos extraídos previamente (en el ejemplo del reconocimiento de voz, serían numerosas grabaciones transcritas) para así intentar *aprender* el verdadero algoritmo, que se el que luego hará la tarea de *predicción*. En definitiva, tenemos dos fases: una primera *fase de entrenamiento* donde se aprende el algoritmo, y una segunda *fase de predicción* en la que se use el algoritmo para resolver la tarea. Esta última fase de predicción suele ser más barata computacionalmente a diferencia que la fase de entrenamiento, la cual es más lenta y necesita de hardware de mayor potencia y coste.

De este modo, este trabajo se centra en la resolución de los problemas intuitivos, evitando que un operador humano se encargue de traducir a la máquina formalmente el conocimiento que necesita. En su lugar, centraremos los esfuerzos en hacer que el computador capture el conocimiento extrayendo patrones de datos en crudo, lo que se conoce como *aprendizaje automático* (*machine learning*).

El rendimiento de estos algoritmos de aprendizaje automático dependen enormemente de la *representación* de los datos. Por ejemplo, si entrenamos un clasificador que estime la probabilidad de que un paciente tenga cáncer de pulmón, el algoritmo no examinará

al paciente directamente. En cambio, el doctor extraerá una serie de *características* del paciente, como su edad, si fuma o no, la densidad de los tejidos, la forma de los órganos, etc., y el algoritmo será capaz de aprender patrones útiles para predecir la probabilidad de que el paciente tenga cáncer de pulmón.

Ahora bien, saber qué características en concreto extraer es una tarea complicada. Si queremos, por ejemplo, desarrollar un programa que detecte cápsulas de medicamentos defectuosas en base a imágenes de estas, quizás podríamos buscar si tienen un agujero o si están chafadas. Sin embargo, describir cómo se ve un agujero o cuál es la forma de la cápsula en términos de valores de píxeles en una imagen es muy difícil, pues esta última se podría ver alterada por un texto impreso en la pastilla, como ocurre en la Figura 1.



(a) Cápsula en buen estado



(b) Cápsula con una perforación

Figura 1: La detección del agujero en la cápsula se ve dificultada por la presencia de un texto que tiene el mismo color.

Una solución a este problema es usar el aprendizaje automático no sólo para devolver una clasificación en base a una representación, sino además para devolver dicha representación como tal. Esto se conoce como *aprendizaje de características* (*representation learning*). Los *autoencodificadores* (*autoencoders*) son un ejemplo de representation learning. Estos combinan un *encodificador*, que transforma los datos de entrada en otra representación, para luego usar un *decodificador* que convierte esta nueva representación de vuelta en el formato original. La idea es entrenar el autoencoder para que preserve la mayor cantidad de información posible cuando reciba un input. El output también guarda ciertas propiedades, aunque de eso, y de los diferentes tipos de autoencoder se hablará más tarde.

Capítulo 1

Introducción al aprendizaje automático

Algunas de las tareas típicas que se trabajan en el machine learning son:

- *Clasificación estadística/Clasificación*: clasificar un *input* en un número finito de *clases*. Un ejemplo es el reconocimiento de voz, donde el input es el audio y las clases son las letras del abecedario (o las palabras del diccionario).
- *Regresión*: se predice un valor numérico dada una entrada. Podría ser el interés de un préstamo dadas las características del prestatario, o los costes médicos anuales esperados que una aseguradora tiene que asumir.
- *Detección de anomalías*: se detectan entradas fuera de la norma, como pueden ser, a modo de ejemplo, la detección de cápsulas defectuosas, errores en la pintura de un coche o transacciones fraudulentas de tarjetas de crédito.
- *Aprendizaje reforzado*: se entrena un agente para tomar la decisión correcta en cada momento según la situación, como hacen los robots de ajedrez o los coches autónomos

Entre muchas otras.

1. Conceptos básicos

En primer lugar, nos centraremos en la **clasificación estadística**. Nuestro objetivo es entrenar un clasificador que, dado un **input**, nos devuelva una **etiqueta** o **clase**. El ejemplo de clasificador por antonomasia es el *OCR* (*Optical Character Recognition*), y, más concretamente, el reconocimiento de números escaneados. El **dataset** más conocido es el MNIST[1], el "Hello world" del aprendizaje automático, que contiene 70000 imágenes de números escritos a mano en formato 28x28 píxeles, i.e. tenemos un conjunto $\mathcal{X} = \{0, 1, \ldots, 255\}^{28\times 28} \subseteq \mathbb{R}^{28\times 28}$ que se conoce como **dominio**, en el cual viven nuestros datos, y queremos etiquetar correctamente, es decir, encontrar una función $h\colon \mathcal{X} \to \mathcal{Y}$ llamada **clasificador** , donde $\mathcal{Y}$ es el **conjunto de etiquetas o clases posibles**. Para

[1]NIST viene de National Institute of Standards and Technology, la agencia que recopiló estos datos. The M viene de "Modified", pues los datos fueron preprocesados para facilitar su uso en el machine learning.

el MNIST, $\mathcal{Y} = \{0, 1, 2, \ldots, 9\}$, y para el ejemplo de detectar si una cápsula es defectuosa (véase Figura 1) podemos escoger $\mathcal{Y}$ como {correcto, defectuoso}, o simplemente $\{0, 1\}$. Cuando $\mathcal{Y}$ tiene dos clases hablamos de **clasificación binaria**. Notamos que en la clasificación estadística el conjunto de clases debería ser finito (y, en general, relativamente pequeños). En la regresión, en cambio, $\mathcal{Y}$ suele ser infinito, y muchas veces igual a $\mathbb{R}$ o un intervalo $[a, b]$.

Dado un dato $x \in \mathcal{X}$, cada una de las coordenadas de la tupla se llaman **atributos** o **features** de x; en este caso el color de un píxel. La función clasificadora h se obtiene mediante un **algoritmo de aprendizaje** que, dado un **conjunto de entrenamiento**, devuelve un clasificador. Dicho conjunto de entrenamiento se trata de un subconjunto finito $S \subseteq \mathcal{X} \times \mathcal{Y}$, es decir, una cantidad finita de muestras ya clasificadas. En el MNIST, una tupla (x, y) del conjunto de entrenamiento se conforma de una imagen de un dígito y el valor de dicho dígito, al que llamamos la **clase verdadera**. Normalmente el conjunto de entrenamiento no tiene ambigüedades, es decir, no contiene $(x, y), x, y', y \neq y'$. Sin embargo, en algunos contextos pueden darse esos casos, como un dos pacientes con los mismos síntomas que han recibido un diagnóstico distinto. Una tal situación puede indicar que nuestros features no son suficientes o no del todo explicativos.

Como ya hemos explicado, nuestro objetivo es etiquetar correctamente todos los datos del dominio. Naturalmente es imposible poner a prueba nuestro clasificador en absolutamente todos los datos del dominio; por eso hemos tomado un conjunto de entrenamiento. Sin embargo, analizar el rendimiento del clasificador en base a su desempeño clasificando datos del conjunto en el que ha sido entrenado es insuficiente. De ser así, el *clasificador memorizador*, es decir, el que memoriza las etiquetas de todos los datos del entrenamiento, sería el mejor en teoría. No obstante, cuando un alumno estudia para un examen, sabe que estudiar de memoria las preguntas de exámenes pasados no suele dar muy buen resultado, porque de esa manera no aprende verdaderamente la estructura de su dataset (también conocido como los conceptos del temario). Un estudiante que haga eso mismo obtendrá una nota muy buena en su proceso de entrenamiento, pero no podrá desenvolverse con soltura durante el examen en el momento en el que le aparezca preguntas nuevas, o los mismos problemas con datos cambiados. En cambio, el estudiante astuto analizará las preguntas de algunos exámenes en busca de extraer los conceptos (los features) que parecen más importantes. Aun cuando los valores numéricos de los problemas cambien, él rendirá igualmente bien ante datos nuevos, ya que se ha centrado en aprender la estructura. Es más, si este estudiante es inteligente, sabrá que no es óptimo analizar todos los exámenes pasados, sino más bien un subconjunto pequeño de estos, con el fin de dedicar los exámenes restantes como testeo de que, en efecto, su método de estudio rinde bien, y sin riesgo de estar sesgado, con preguntas nuevas nunca antes estudiadas. Este mismo concepto se traslada al machine learning: ante una muestra limitada de datos, centrarse en memorizarlos da malos resultados en comparación con esforzarse a aprender la estructura[2], y la valoración del rendimiento del clasificador debería basarse en su desempeño en datos nunca antes vistos, evitando todo sesgo y simulando un entorno del mundo real. Dicho conjunto se conoce como **conjunto de testeo** o **test set**. El procedimiento usual es reservar una fracción de los datos disponibles para el testeo del clasificador en datos que nunca haya visto. Suele ser una fracción pequeña, entorno al 20 %, para que el algoritmo

[2]Normalmente los estudiantes tienen acceso a más información en forma de libros así como apuntes de clase, pero un planteamiento como este en el que se asume la inaccesibilidad del alumno a esos datos tampoco parece alejarse mucho de la realidad en algunos casos.

de aprendizaje posea la mayor cantidad posible de datos con los que aprender.

Es más, en comparación con el primer alumno, el memorizador, parecería que el estudiante astuto ha tenido que memorizar menos en realidad. Es cierto que ha necesitado más esfuerzo en su proceso de entrenamiento, pero, una vez terminado el estudio, no está guardando más información en su cabeza que el primero, pues no ha tenido que memorizar valores numéricos innecesarios de problemas cuya generalización hubiera resultado, aunque trabajosa de obtener, más ligera de memorizar.

1.1. Subsección

Una sección dentro de una sección se denomina subsección.

1.2. Subsección

Una sección dentro de una sección se denomina subsección.

Subsubsección

Esto es una sección dentro de una subsección, o sea, una subsubsección.

Capítulo 2

Título del capítulo

Se dice que estos datos (imágenes, en este caso) están **etiquetados**, pues la imagen por sí sola no le bastaría al algoritmo para aprender qué número es cual. Es lo que se conoce como *aprendizaje supervisado* (*supervised learning*). En contraposición, existen los algoritmos de *aprendizaje no supervisado* (*unsupervised learning*), los cuales se centran en aprender la distribución de los datos para así descubrir propiedades interesantes en la estructura de estos.

La línea entre lo que es aprendizaje supervisado y lo que es no supervisado es algo fina, y no son términos totalmente formales. Muchos algoritmos de aprendizaje automático pertenecen a ambos grupos al mismo tiempo. Sin ir más lejos, el MNIST se puede ver como diez conjuntos por separado cada uno conteniendo un dígito distinto. Aprender la estructura de esos diez conjuntos es equivalente a etiquetar correctamente un número dentro del dataset que contiene todos. De hecho, si tomamos un vector $x \in \mathcal{X}$, y estimásemos la probabilidad $p(x, y), y \in \mathcal{Y}$, es decir, de que x sea una foto de un dígito $y \in \{1, \ldots, 9\}$ en concreto, entonces, calculando

$$p(y|x) = \frac{p(x, y)}{\sum_{y'=1}^{10} p(x, y')},$$

y tomando $y \in \mathcal{Y}$ que maximice ese número, podríamos clasificar una imagen únicamente con conocimiento que nos aportan algoritmos de aprendizaje no supervisado.

Este ejemplo es algo estúpido, pues nosotros hemos hecho ya el *clustering* o agrupamiento de los datos en el momento en el que dividíamos el dataset según su etiqueta. Sin embargo, veremos más tarde diversas técnicas en las que el uso de datos no etiquetados pueden ayudar en la tarea de clasificación.

1. Una primera sección

Esta es la primera sección del segundo capítulo.

1.1. Subsección

Una sección dentro de una sección se denomina subsección.

1.2. Subsección

Una sección dentro de una sección se denomina subsección.

Subsubsección

Esto es una sección dentro de una subsección, o sea, una subsubsección. Esto es un ejemplo de cita [2]

Bibliografía

[1] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. `http://www.deeplearningbook.org`.

[2] E. I. Zelmanov. Lie algebras with finite gradation. *Mat. Sb. (N.S.)*, 124(166)(3):353–392, 1984.